

Санкт-Петербургский государственный университет  
Прикладная математика и информатика

Производственная практика 1 (научно-исследовательская работа) (семестр 2)

ИСПОЛЬЗОВАНИЕ МЕТОДА SSA В МАШИННОМ ОБУЧЕНИИ ДЛЯ  
ПРОГНОЗА ВРЕМЕННЫХ РЯДОВ

Выполнил:

Ежов Федор Валерьевич

группа 20.М03-мм

Научный руководитель:

к.физ.-мат.н., доцент

Голяндина Нина Эдуардовна

Кафедра Статистического Моделирования

Санкт-Петербург

2021

# Оглавление

<b>Введение</b>	4
<b>Глава 1. Singular Spectrum Analysis</b>	5
1.1. Алгоритм SSA	5
1.1.1. Этап 1. Построение траекторной матрицы (Вложение)	5
1.1.2. Этап 2. Singular Value Decomposition (SVD)	6
1.1.3. Этап 3. Группировка первых $r$ собственных троек	6
1.1.4. Этап 4. Диагональное усреднение	7
<b>Глава 2. Использование SSA в машинном обучении</b>	8
2.1. Задача	8
2.2. Подготовка данных	8
2.2.1. SSA-preprocessing	8
2.3. Модель	10
2.4. Прогнозирование	11
2.5. Метрики	12
<b>Глава 3. SSA &amp; ANN</b>	13
3.1. Синус с шумом	13
3.1.1. Постановка задачи	13
3.1.2. Модели	14
3.1.3. Подготовка данных	14
3.1.4. Обучение и прогнозирование	15
3.1.5. Результаты	15
3.2. Реальный ряд	16
3.2.1. Постановка задачи	16
3.2.2. Модели	17
3.2.3. Данные, обучение и прогнозирование	17
3.2.4. Результаты	17
3.3. Итоги	18
<b>Заключение</b>	19

<b>Список литературы</b> . . . . .	20
------------------------------------	----

## Введение

Метод Singular Spectrum Analysis (SSA) — хорошо развитая методология анализа и прогнозирования временных рядов, которая включает в себя множество различных, но взаимосвязанных методов. Область применения SSA очень широка — от непараметрической декомпозиции и фильтрации временных рядов до оценки параметров и прогнозирования.

Artificial neural network (ANN) — математическая модель, построенная по принципу организации и функционирования биологических нейронных сетей — сетей нервных клеток живого организма. Нейронная сеть представляет собой частный случай методов распознавания образов, дискриминантного анализа, методов кластеризации и т.п.

В прошлом отчете обозревалась статья «The incorrect usage of singular spectral analysis and discrete wavelet transform in hybrid models to predict hydrological time series» [2], в которой говорилось, что использование гибридных моделей SSA-ANN ведет к значительным улучшениям в точности предсказания из-за заглядывания в будущее. Из-за чего преимущество гибридных моделей пропадает при корректном тестировании методов. В этой работе поставлена следующая задача: проверить возможность прироста точности при использовании гибридных моделей SSA-ANN в сравнении с обычными моделями ANN.

## Глава 1

## Singular Spectrum Analysis

Метод SSA используется для разложение исходного ряда в сумму рядов, которые легко интерпретировать и понять их поведение. Обычно исходный ряд раскладывается в сумму трех рядов: тренд — медленно меняющаяся компонента, сезонность — циклическая компонента с фиксированным периодом и шум. Информацию про базовый алгоритм SSA и связанные с методом фундаментальные понятия можно найти в книге «Analysis of time series structure: SSA and related techniques» [1].

## 1.1. Алгоритм SSA

Алгоритм SSA состоит из четырех этапов:

1. Построение траекторной матрицы (Вложение).
2. SVD.
3. Группировка первых  $r$  собственных троек.
4. Диагональное усреднение.

Рассмотрим каждый этап подробнее.

Пусть  $X_N = (x_1, \dots, x_N)$  — временной ряд, где  $N > 3$ . Также будем предполагать, что найдется хоть одно  $x_i \neq 0$ , то есть ряд не нулевой. Обычно считается, что  $x_i = f(i\Delta)$  для некоторой функции  $f(t)$ , где  $t$  — время, а  $\Delta$  — некоторый временной интервал.

## 1.1.1. Этап 1. Построение траекторной матрицы (Вложение)

Выберем целое  $L$  — длина окна, такое что  $1 < L < N$ . Тогда  $K = N - L + 1$ . Построим вектора  $X_i = (x_i, \dots, x_{i+L-1})^T$ , для  $1 \leq i \leq K$ . Составим из векторов  $X_i$  траекторную матрицу:

$$\mathbf{X} = [X_1 : \dots : X_K] = \begin{pmatrix} x_1 & x_2 & x_3 & \dots & x_K \\ x_2 & x_3 & x_4 & \dots & x_{K+1} \\ x_3 & x_4 & x_5 & \dots & x_{K+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & x_{L+2} & \dots & x_N \end{pmatrix}.$$

Получили матрицу  $\mathbf{X}$  размерностью  $L \times K$ , составленную из пересекающихся частей исходного временного ряда. Можно заметить, что на побочных диагоналях стоят одинаковые числа, такая матрица называется ганкелевой. Существует взаимно-однозначное соответствие между ганкелевыми матрицами  $L \times K$  и рядами длиной  $N = L + K - 1$ .

Операцию получения из ряда  $X_N$  траекторную матрицу  $\mathbf{X}$  обозначим:

$$\mathbf{X} = \mathcal{T}_L(X_N),$$

соответственно обратная операция будет обозначаться:  $\mathcal{T}^{-1}$ .

### 1.1.2. Этап 2. Singular Value Decomposition (SVD)

На данном этапе применяется метод SVD к траекторной матрице  $\mathbf{X}$ . Пусть  $\mathbf{S} = \mathbf{X}\mathbf{X}^T$  и  $\lambda_1 > \dots > \lambda_L$  — собственные числа матрицы  $\mathbf{S}$ ,  $U_1, \dots, U_L$  — ортонормированная система базисных векторов, соответствующих собственным числам. Обозначим  $V_i = \frac{X^T U_i}{\sqrt{\lambda_i}}$  и  $d = \max\{i : \lambda_i > 0\}$ . Тогда сингулярное разложение матрицы  $\mathbf{X}$  запишется следующим образом:

$$\mathbf{X} = \mathbf{X}_1 + \dots + \mathbf{X}_d, \text{ где } \mathbf{X}_i = \sqrt{\lambda_i} U V^T,$$

Набор  $(\sqrt{\lambda_i}, U_i, V_i^T)$  будем называть  $i$ -й собственной тройкой.

### 1.1.3. Этап 3. Группировка первых $r$ собственных троек

На этапе группировки из всех значений  $\{1 \dots d\}$  берутся первые  $r$ . Пусть,  $I = \{1, \dots, r\}$ , тогда результирующая матрица соответствующая группе  $I$  имеет вид:  $\mathbf{X}_I = \mathbf{X}_1 + \dots + \mathbf{X}_r$ .

#### 1.1.4. Этап 4. Диагональное усреднение

Пусть  $\mathbf{Y}$  — матрица  $L \times K$ ,  $L < K$ .  $y_{ij}$  — элементы матрицы, где  $1 \leq i \leq L$ ,  $1 \leq j \leq K$ . Также пусть  $N = L + K - 1$ . Диагональное усреднение преобразует матрицу  $\mathbf{Y}$  в ряд  $g_0, \dots, g_{N-1}$  по формуле:

$$g_k = \begin{cases} \frac{1}{k+1} \sum_{m=1}^{k+1} y_{m, k-m+2} & , \text{ для } 0 \leq k < L-1 \\ \frac{1}{L} \sum_{m=1}^L y_{m, k-m+2} & , \text{ для } L-1 \leq k < K \\ \frac{1}{N-k} \sum_{m=k-K+2}^{N-K+1} y_{m, k-m+2} & , \text{ для } K \leq k < N \end{cases}$$

Применяя диагональное усреднение к результирующей матрице группы  $I$ , получаем ряд  $\hat{\mathbf{F}} = (f_1 \cdots f_{N-1})$ . Полученный ряд  $\hat{\mathbf{F}}$  назовем оценкой сигнала, полученной с помощью SSA. Процедуру выделения сигнала с помощью SSA обозначим как:

$$\hat{\mathbf{F}} = SSA_{L,r}(\mathbf{F}),$$

где  $L$  — длина окна в SSA,  $r$  — количество первых собственных троек, участвующие в построении  $\hat{\mathbf{F}}$ .

## Глава 2

# Использование SSA в машинном обучении

### 2.1. Задача

Рассмотрим  $Z_N$  — временной ряд длины  $N$  и задачу: с помощью Artificial Neural Network (ANN) модели на основе  $T$  последовательных точек ряда  $Z_N$ , предсказать следующие  $R$  точек ряда. Решение данной задачи, можно разбить на несколько частей: подготовка данных, обучение модели, прогнозирование.

### 2.2. Подготовка данных

$Z_N$  — изначальный временной ряд длиной  $N$ . Мы можем представить ряд в виде траекторной матрицы для длины окна  $T + R$ , тогда получим:

$$\mathbf{Z} = \mathcal{T}_{T+R}(Z_N) = \left( \begin{array}{cccc|cccc} z_1 & z_2 & \cdots & z_T & z_{T+1} & \cdots & z_{T+R-1} & z_{T+R} \\ z_2 & z_3 & \cdots & z_{T+1} & z_{T+2} & \cdots & z_{T+R} & z_{T+R+1} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots \\ z_{N-T-R+1} & z_{N-T-R+2} & \cdots & z_{N-R} & z_{N-R+1} & \cdots & z_{N-1} & z_N \end{array} \right).$$

Матрица  $\mathbf{Z}$  будет размерности  $(N - T - R + 1) \times (T + R)$ . Левую часть матрицы  $\mathbf{Z}$  назовем  $\mathbf{Z}^x$ , а правую часть  $\mathbf{Z}^y$ . Также разобьем матрицу по строчкам на 3 части: train, val, test. Пусть  $\tau$ ,  $v$  и  $t$  номера последних строчек в каждой соответствующей части. Обозначим с помощью  $\mathbf{Z}_{a,b}^{(c,d)}$  часть матрицы  $\mathbf{Z}$  с  $a$  по  $b$  строчку и с  $c$  по  $d$  столбец. Тогда train, val, test части записываются как:  $\mathbf{Z}_{train} = \mathbf{Z}_{1,\tau}^{(1,T+R)}$ ,  $\mathbf{Z}_{val} = \mathbf{Z}_{\tau+T+R,v}^{(1,T+R)}$ ,  $\mathbf{Z}_{test} = \mathbf{Z}_{v+T+R,t}^{(1,T+R)}$ . В этих же обозначениях  $\mathbf{Z}^x = \mathbf{Z}_{1,t}^{(1,T)}$ ,  $\mathbf{Z}^y = \mathbf{Z}_{1,t}^{(T+1,T+R)}$ .

#### 2.2.1. SSA-preprocessing

Предобработка SSA для тренировочной выборки описывается следующим алгоритмом.  $L, r$  — гипер-параметры, описанные в разделе «1.1. Алгоритм SSA»:

1. Преобразуем train часть матрицы  $\mathbf{Z}$  во временной ряд  $\tilde{\mathbf{Z}} = \mathcal{T}^{-1}(\mathbf{Z}_{train})$ .
2. Получим ряд  $\hat{\mathbf{Z}} = SSA_{L,r}(\tilde{\mathbf{Z}})$ .



3. Получаем траекторную матрицу  $\hat{\mathbf{Z}} = \mathcal{T}_{T+R}(\hat{\mathbf{Z}})$ .
4. Полученная траекторная матрица  $\hat{\mathbf{Z}}$  будет результатом работы предобработки SSA для тренировочной выборки.

Предобработка SSA для валидационной или тестовой выборки отличается от предыдущей, ввиду разных предназначений выборок. В отличие от тренировочной выборки о которой мы знаем все, считается, что о валидационной и тестовой выборках ничего не известно. В этих случаях SSA-обработку следует применять так, чтобы предыдущие значения ряда не получали информации от будущих («заглядывание в будущее»).

Пусть  $\mathbf{Z}_{b,e} = [z_b, z_{b+1}, \dots, z_e]$  подряд ряда  $\mathbf{Z}$ , где  $b$  — начальный индекс,  $e$  — конечный индекс. Пусть  $p$  — тоже индекс ряда, такой что  $b < p < e$ . Следующий алгоритм описывает процедуру получения ряда  $\mathbf{Z}_{p+1,e}$ , обработанного с помощью SSA без «заглядывание в будущее»:

1. Пусть есть ряд  $\mathbf{Z}_{b,e}$  и задано  $p$ . Тогда  $Q = e - p$  — размер ряда  $\mathbf{Z}_{p+1,e}$ . Пусть  $\hat{\mathbf{Z}}_Q = (\hat{z}_1, \dots, \hat{z}_Q)$  — ряд размера  $Q$ .
2. Для каждого  $i = [1, \dots, Q]$  получим  $\hat{\mathbf{Z}}'_{b+i-1,p+i} = \text{SSA}_{L,r}(\mathbf{Z}_{b+i-1,p+i})$ , присвоим значение последнего элемента полученного ряда  $\hat{z}'_{p+i}$  значению ряда  $\hat{\mathbf{Z}}_Q$  с соответствующим индексом, то есть  $\hat{z}_i = \hat{z}'_{p+i}$ .
3. Получили ряд  $\hat{\mathbf{Z}}_Q$  размера  $Q$ , значения которого являются значениям ряда  $\mathbf{Z}_{p+1,e}$ , обработанные с помощью SSA без «заглядывания в будущее».

Процедуру получения  $\hat{\mathbf{Z}}_Q$  обозначим:  $\hat{\mathbf{Z}}_Q = \text{SSA}^{(p)}(\mathbf{Z}_{b,e})$ . Тогда алгоритм предобработки для валидационной выборки запишется следующим образом:

1. Запишем  $\mathbf{Z}_{1,v}^{(1,T+R)}$  как  $\mathbf{Z}_{1,v+T+R}$ .
2. Выберем  $p = \tau + T + R$ .
3. Получим  $\hat{\mathbf{Z}}_Q = \text{SSA}^{(p)}(\mathbf{Z}_{1,v+T+R})$ .
4. Перейдем обратно к траекторной матрице  $\hat{\mathbf{Z}}_{val} = \mathcal{T}_{T+R}(\hat{\mathbf{Z}}_Q)$ .

$\hat{\mathbf{Z}}_{val}$  — будет результатом предобработки SSA для валидационной выборки. Размерность  $\hat{\mathbf{Z}}_{val}$  будет совпадать с размерностью  $\mathbf{Z}_{val}$ .

Запишем аналогичный алгоритм для тестовой выборки:

1. Запишем  $\mathbf{Z}_{1,t}^{(1,T+R)}$  как  $\mathbf{Z}_{1,t+T+R} = \mathbf{Z}_N$ .
2. Выберем  $p = v + T + R$ .
3. Получим  $\hat{\mathbf{Z}}_Q = \mathcal{SSA}^{(p)}(\mathbf{Z}_N)$ .
4. Перейдем обратно к траекторной матрице  $\hat{\mathbf{Z}}_{test} = \mathcal{T}_{T+R}(\hat{\mathbf{Z}}_Q)$ .

$\hat{\mathbf{Z}}_{test}$  — будет результатом предобработки SSA для тестовой выборки.

## 2.3. Модель

ANN включает в себя входной слой, ряд скрытых слоев и выходной слой, каждый слой содержит несколько узлов. Считается, что ANN с одним скрытым слоем обеспечивает достаточную сложность для моделирования нелинейных взаимосвязей данных. ANN в этой работе формализуется следующим образом:

$$\hat{X}^T = [x_1, \dots, \hat{x}_T]$$

— входные данные, на которых модели учиться делать предсказания.

$$\hat{Y}^T = [y_1, \dots, \hat{y}_R]$$

— выходные данные, предсказания модели.

$$y_k = \phi_2 \left( \sum_{j=1}^h w_{jk} \phi_1 \left( \sum_{i=1}^T w_{ij} x_i + \theta_j^{(1)} \right) + \theta_k^{(2)} \right), k = [1, \dots, R],$$

где  $T$  — размер входного вектора на котором выполняется прогноз,  $h$  — размер скрытого слоя.  $w$  и  $\theta$  — веса модели.  $\phi$  — функция активации.  $R$  — размер выходного вектора-прогноза.

Ниже представлен список некоторых функций активаций:

1. Линейная функция активации:  $\phi(x) = x$ .

2. Сигмоида:  $\phi(x) = \frac{1}{1 + e^{-x}}$ .

3. ReLU:  $\phi(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases}$

**Обучение** Оптимизация параметров модели ANN  $w, \theta$  проводится с помощью процедуры обратного распространения ошибки на тренировочной выборке. Модель учится по  $\mathbf{Z}_{train}^x$  предсказывать  $\mathbf{Z}_{train}^y$ . Эпоха — цикл прохода всех строчек из тренировочной выборки в обучении. Количество эпох для обучения является гипер-параметром. На валидационной выборке оценивается оптимальное количество эпох, нужных для модели (дабы избежать переобучения).

Перед началом обучения нужно выбрать гипер-параметры модели  $\phi_1, \phi_2, h$  и количество эпох. Алгоритм обучения модели после выбора архитектуры:

1. Инициализация модели со случайными весами.
2. На тренировочной выборке  $\mathbf{Z}_{train}$  оптимизируются веса  $w, \theta$  с заданным количеством эпох. Модель учится по данным строчкам  $\mathbf{Z}_{train}^x$  предсказывать соответствующие строчки  $\mathbf{Z}_{train}^y$ . Для каждой  $i$ -ой эпохи считается  $\epsilon_i$  — ошибка на валидационной выборке. Для валидационной выборки  $\mathbf{Z}_{val}^x$  строится прогноз  $\hat{\mathbf{Z}}_{val}^y$ . Ошибка  $\epsilon_i$  получается сравнением  $\hat{\mathbf{Z}}_{val}^y$  с  $\mathbf{Z}_{val}^y$  по какой-нибудь метрике (например MSE).
3. Находим  $i : \min(\epsilon_i)$ .
4. Веса модели сбрасываются (снова инициализация случайными весами).
5. Снова на тренировочной выборке оптимизируются веса  $w, \theta$  с количеством эпох равных  $i$ .

## 2.4. Прогнозирование

После того как модель обучена, можно перейти к прогнозированию точек ряда.

1. Возьмем  $\mathbf{Z}_{test}^x$  и  $\mathbf{Z}_{test}^y$ .
2. Представим  $\mathbf{Z}_{test}^x = [Z_{test}^{x,1} : \dots : Z_{test}^{x,Q}]^T$ , где  $Q$  — количество строчек в тестовой матрицы  $\mathbf{Z}_{test}$ .
3. Для каждой строчки матрицы  $\mathbf{Z}_{test}^x$  получаем прогноз с помощью обученной модели. Запишем результат прогноза как матрицу  $\hat{\mathbf{Z}}^y = [\hat{Z}^{y,1} : \dots : \hat{Z}^{y,Q}]^T$ .
4. Далее можно сравнить  $\hat{\mathbf{Z}}^y$  с  $\mathbf{Z}_{test}^y$  по какой-нибудь метрике.

## 2.5. Метрики

С помощью метрик MSE и RMSE можно мерить размер ошибки полученного прогноза.

$$MSE(\mathbf{Z}_{test}^y, \hat{\mathbf{Z}}^y) = \frac{1}{Q} \text{diag}((\mathbf{Z}_{test}^y - \hat{\mathbf{Z}}^y)(\mathbf{Z}_{test}^y - \hat{\mathbf{Z}}^y)^T)$$

$$RMSE(\mathbf{Z}_{test}^y, \hat{\mathbf{Z}}^y) = \sqrt{MSE(\mathbf{Z}_{test}^y, \hat{\mathbf{Z}}^y)}$$

## Глава 3

## SSA &amp; ANN

В этой главе описано два эксперимента, в которых сравнивается простая модель ANN и гибридная модель SSA-ANN на примере синуса с шумом и реальных данных.

## 3.1. Синус с шумом

Так как реальные данные, рассмотренные во втором эксперименте в разделе «3.2 Реальный ряд» похожи на сумму синусов с разной амплитудой, мы хотим показать, что SSA дает прирост в точности в задаче прогнозирования синуса с шумом.

## 3.1.1. Постановка задачи

Рассмотрим следующий ряд  $Z_{1500}$ , состоящий из элементов  $z_i = \sin(2\pi\omega i) + \epsilon_i$ , где  $\omega$  – частота, равная  $\frac{1}{12}$ ,  $\epsilon_i$  – шум из стандартного нормального распределения  $N(0, 1)$ .




Рис. 3.1. Часть ряда  $Z_{1500}$ .

Поставим задачу предсказывать следующую точку синуса по двенадцати предыдущим, то есть возьмем  $T = 12$  и  $R = 1$ . В рамках этой задачи хотим сравнить обычную модель ANN и гибридные модели SSA-ANN по метрике RMSE. Также мы будем сравнивать отклонение полученного прогноза от сигнала  $\sin(2\pi\omega i)$  и самого ряда  $Z_{1500}$ .

Мы будем рассматривать две версии гибридных моделей SSA-ANN. В первой версии обработка методом SSA будет применяться для левой части  $\mathbf{Z}^x$  траекторной матрицы. Таким образом мы хотим проверить гипотезу о том, что точность ANN повысится, если прогноз будет строиться на данных, очищенных от шума. Такие модели будем называть SSA-X-ANN. Во второй версии только правая часть  $\mathbf{Z}^y$  обрабатывается с помощью метода SSA. В этом случае мы хотим проверить гипотезу, что точность модели ANN повысится, если модель будет обучаться прогнозировать данные без шума. Такие модели будем называть SSA-Y-ANN.

### 3.1.2. Модели

Для предсказаний воспользуемся нейронной сетью, описанной в разделе «2.3 Модель». Назовем ANN-1 – модель без скрытых слоев и обе функций активации являются линейными. Она соответствует обычной линейной регрессии. ANN-2 – назовем модель с одним скрытым слоем, размера 50.  $\phi_1$  – является функцией активации ReLU, а  $\phi_2$  – линейная функция активации. SSA-ANN-1 и SSA-ANN-2 назовем группы гибридных версии для каждой модели. Стоит отметить, что гибридные модели могут быть разными, мы будем рассматривать по две гибридные модели, которые были описаны в разделе «3.1.1. Постановка задачи», для каждой обычной (например, SSA-X-ANN-1 или SSA-Y-ANN-2).

### 3.1.3. Подготовка данных

Построим траекторную матрицу для ряда  $\mathbf{Z}_{1500}$  с окном длиной 13.

$$\mathbf{Z} = \mathcal{T}_{13}(\mathbf{Z}_{1500}) = \left( \begin{array}{cccc|c} z_1 & z_2 & \cdots & z_{12} & z_{13} \\ z_2 & z_3 & \cdots & z_{13} & z_{14} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ z_{1488} & z_{1489} & \cdots & z_{1499} & z_{1500} \end{array} \right).$$

Разобъем данные на тренировочную, валидационную и тестовую выборку следующим образом:  $\tau = 988$ ,  $v = 1238$  и  $t = 1488$ . Далее для моделей ANN-1 и ANN-2 будем использовать уже полученную матрицу  $\mathbf{Z}$  без каких-то обработок методом SSA. Параметры оператора  $SSA_{L,r}$  задаются следующим образом  $L = \frac{\tau + 12}{2}$ ,  $r = 2$ . Для гибридных моделей SSA-X-ANN-1 и SSA-X-ANN-2 обработаем только левую часть мат-

рицы  $\mathbf{Z}$  методом SSA, как описано в разделе «2.2.1. SSA-preprocessing». Для гибридных моделей SSA-Y-ANN-1 и SSA-Y-ANN-2 обрабатываем только правую часть матрицы  $\mathbf{Z}$  методом SSA. Таким образом получили для каждой модели свою матрицу  $\mathbf{Z}$ .

### 3.1.4. Обучение и прогнозирование

Теперь когда для каждой модели есть своя матрица  $\mathbf{Z}$ , их можно обучить как описано параграфе «обучение» раздела «2.3. Модель». После обучения модели тестируются на тестовой выборке по алгоритму, описанному в разделе «2.4. Прогнозирование».

### 3.1.5. Результаты

В ходе эксперимента полученные результаты для моделей ANN-1 и SSA-ANN-1 представлены в таблице 3.1. Результаты для моделей ANN-2 и SSA-ANN-2 представлены в таблице 3.2.

	ANN-1	SSA-X-ANN-1	SSA-Y-ANN-1
Signal	0.414	0.086	0.409
Time series	1.043	0.998	1.037

Таблица 3.1. RMSE для моделей ANN-1 и SSA-ANN-1.

	ANN-2	SSA-X-ANN-2	SSA-Y-ANN-2
Signal	0.415	0.014	0.365
Time series	1.045	1.007	1.032

Таблица 3.2. RMSE для моделей ANN-2 и SSA-ANN-2.

На результатах выше можно наблюдать, что гибридные модели показывают результаты лучше, чем обычная модель. Модели SSA-Y-ANN показывают результат сравнимый с обычной моделью, можно сказать, что в этом случае улучшение незначительное. В случае моделей SSA-X-ANN видно хорошее улучшение. Наблюдается снижение ошибки по RMSE на 0.04. Также посмотрим на ошибки для сигнала и ряда в случае SSA. Видно, что квадрат ошибки отличается на дисперсию шума  $\sigma^2$  для моделей SSA-ANN первой версии, что говорит о том, что метод SSA удалил из ряда шумовые компоненты. В случае же модели ANN разница между ошибками примерно половина  $\sigma^2$ . Из этого

следует, что модели SSA-X-ANN в отличие от ANN пытается прогнозировать чистый сигнал, что дает лучшие результаты.

Можно заключить, что для обеих архитектур моделей наблюдается одна тенденция: гибридные модели показывают результаты лучше, чем обычные. В частности, гибридные модели SSA-X-ANN показывает наилучшие результаты. Можно сказать, что правильное использование гибридных моделей SSA-ANN дает прирост в точности в задаче прогнозирования синуса с шумом.

## 3.2. Реальный ряд

Теперь, когда мы убедились, что гибридные модели работают лучше, чем обычные в задачи прогнозирования синуса с шумом, перейдем к прогнозированию реального ряда.

### 3.2.1. Постановка задачи

Рассмотрим следующий ряд  $Z_{1500}$  (рис. 3.2) взятый из статьи [2]. На ряде отображены среднемесячное количество осадков в Индии.




Рис. 3.2. Ряд  $Z_{1500}$ .

Поставим задачу предсказывать следующую точку ряда  $Z_{1500}$  по двенадцати предыдущим, то есть возьмем  $T = 12$  и  $R = 1$ . В рамках этой задачи хотим сравнить обычную модель ANN и гибридные модели SSA-ANN по метрике RMSE. Также как и в главе «3.1.



Синус с шумом» рассмотрим две версии гибридных моделей SSA-ANN. В первой версии обработка методом SSA будет применяться для левой части  $\mathbf{Z}^x$  траекторной матрицы. Во второй версии только правая часть  $\mathbf{Z}^y$  обрабатывается с помощью метода SSA. Будем использовать такие же обозначения для этих моделей как и в разделе «3.1. Синус с шумом».

### 3.2.2. Модели

Для предсказаний воспользуемся обычными моделью ANN-2 и гибридными SSA-ANN-2, описанными ранее в разделе «3.1.2 Модели».

### 3.2.3. Данные, обучение и прогнозирование

Построим траекторную матрицу для ряда  $\mathbf{Z}_{1500}$  с окном длиной 13.

$$\mathbf{Z} = \mathcal{T}_{13}(\mathbf{Z}_{1500}),$$

Разобьем данные на тренировочную, валидационную и тестовую выборку следующим образом:  $\tau = 988$ ,  $v = 1238$  и  $t = 1488$ .

Далее для модели ANN-2 будем использовать уже полученную матрицу  $\mathbf{Z}$  без каких-то обработок методом SSA. Параметры оператора  $SSA_{L,r}$  задаются следующим образом  $L = \frac{\tau + 12}{2}$ ,  $r = 7$ . Для гибридной модели SSA-X-ANN-2 обработаем только левую часть матрицы  $\mathbf{Z}$  методом SSA, как описано в разделе «2.2.1. SSA-preprocessing». Для гибридной модели SSA-Y-ANN-2 обработаем только правую часть матрицы  $\mathbf{Z}$  методом SSA. Таким образом получили для каждой модели свою матрицу  $\mathbf{Z}$ .

Теперь когда для каждой модели есть своя матрица  $\mathbf{Z}$ , их можно обучить как описано в параграфе «обучение» раздела «2.3. Модель». После обучения, модели тестируются на тестовой выборке по алгоритму, описанному в разделе «2.4. Прогнозирование».

### 3.2.4. Результаты

В ходе эксперимента получились для моделей ANN-2 и SSA-ANN-2 следующие результаты, представленные на таблице 3.3.

На таблице видна такая же тенденция, как и в задаче с синусом с шумом. Модели ANN и SSA-Y-ANN-2 показывают сравнительно похожие результаты. А вот модель SSA-X-ANN-2 показывает наилучшие результаты

	ANN-2	SSA-X-ANN-2	SSA-Y-ANN-2
RMSE	239.84	218.57	242.72

Таблица 3.3. RMSE для моделей ANN-2 и SSA-ANN-2.

Можно заключить, что с помощью гибридной модели удалось улучшить точность прогнозирования реального ряда.

### 3.3. Итоги

Исходя из результатов полученных в экспериментах, описанных ранее, можно заключить, что правильное использование гибридных моделей SSA-ANN приводит к весьма хорошим улучшениям в задаче прогнозирования рядов.

## Заключение

В работе был рассмотрен алгоритм SSA, использующий в гибридных моделях SSA-ANN, как предобработка данных. Были описаны эксперименты в которых сравнивались обычные модели ANN и гибридные модели SSA-ANN в разных задачах. Для всех сравнений были приведены результаты в метрике RMSE. Также была описана математическая база, заложенная в основу всех экспериментов. В ходе всех экспериментов удалось достичь улучшения точности с помощью гибридных моделей SSA-ANN по сравнению с обычными моделями ANN.

## Список литературы

1. Golyandina, N., Nekrutkin, V., & Zhigljavsky, A. (2001). Analysis of time series structure: SSA and related techniques. Chapman & Hall/CRC.
2. Kongchang Du, Ying Zhao, Jiaqiang Lei (2017). The incorrect usage of singular spectral analysis and discrete wavelet transform in hybrid models to predict hydrological time series.